



RAG Wissensdatenbank

Handbuch • Installation & Bedienung

V1.0

Stand: 23. Juni 2026 • **Tech-IT Consulting**

Inhaltsverzeichnis

Installation – RAG Wissensdatenbank

Variante A – Zielsever hat Internet (Online)

Variante B – Zielsever offline / air-gapped

Nach der Installation

Bedienungsanleitung – RAG Wissensdatenbank

1. Anmelden
2. Fragen stellen (Chat)
3. Spracheingabe (Mikrofon)
4. Darstellung (Light/Dark)
5. Einstellungen (Zahnrad)
6. Verwaltung (Admin)
7. Lizenz eintragen
8. Häufige Probleme

Installation – RAG Wissensdatenbank

V1.0 · Stand: 2026-06-23

Die Anwendung ist ein Docker-Stack aus zwei Containern:

- **rag-backend** – FastAPI + Web-UI (statisch eingebaut), Embedding/Reranking, Whisper.
- **rag-qdrant** – Vektordatenbank (Qdrant).

Modelle (Embedding `e5-large` ~2 GB, Reranker, Whisper) liegen im Volume `models`, die eingelesene Wissensbasis im Volume `qdrant_storage`. Persistente Einstellungen (`config.json`, `users.json`) liegen im gemounteten `backend/`-Verzeichnis.

Es gibt zwei Installationswege – je nachdem, ob der Zielservers Internet hat.

Variante A – Zielservers hat Internet (Online)

Kein Export vom Quell-Server nötig.

1. Ordner `rag-wissensdatenbank/` auf den Zielservers kopieren (mindestens `backend/` und `docker-compose.yml`).
2. `.env` anlegen: `bash cp .env.example .env && nano .env` # Admin, `RAG_LICENSE_SECRET`, ggf. Keys
3. Bauen und starten (lädt Images + Modelle automatisch, erster Start dauert): `bash docker compose up -d --build`
4. Web-UI öffnen (Port 80, alt. `:8000`), als Admin anmelden, Engines/SMB konfigurieren, **Lizenzschlüssel** unter *Einstellungen* → *Allgemein* → *Lizenz* eintragen, Dokumente indizieren.

Variante B – Zielservers offline / air-gapped

Hier wird auf dem **Quell-Server** (mit laufendem Stack) ein Bundle erzeugt, das Images **und** Modelle enthält – auf dem Ziel wird nichts heruntergeladen.

1. Bundle erzeugen (auf dem Quell-Server, z. B. vm-rag)

```
cd /opt/rag
# Skripte aus dem Repo hierher kopieren (einmalig), dann:
bash make-offline-bundle.sh           # leere Wissensbasis
bash make-offline-bundle.sh --with-data # inkl. vorhandenem Qdrant-Index
```

Ergebnis: `rag-wissensdatenbank-offline-JJJJMMTT.tar.gz` (~5 GB).

2. Auf den Zielserver kopieren & installieren

```
# z. B. per USB/scp auf den Zielserver bringen, dann dort:
tar xzf rag-wissensdatenbank-offline-*.tar.gz
nano .env.example    # bei Bedarf, wird als .env übernommen
bash install-offline.sh
```

Das Skript lädt die Images (`docker load`), spielt die Modelle ins Volume, fragt nach der ausgefüllten `.env` und startet den Stack.

Voraussetzung am Ziel: Docker + Docker-Compose-Plugin sind installiert (diese müssen auf einem komplett offline System vorab eingerichtet sein).

Nach der Installation

- **Lizenz:** Ohne gültigen Schlüssel läuft die App 30 Tage Test + 10 Tage Kulanz, danach ist der Chat gesperrt. Schlüssel im Lizenz Admin (Produkt **RAGW**) ausstellen und in den Einstellungen eintragen. `RAG_LICENSE_SECRET` in der `.env` muss dem Produkt-Secret entsprechen.
- **Lokale Engine:** `OLLAMA_URL` muss auf ein vom Server erreichbares Ollama zeigen. Ohne lokales Ollama eine Cloud-Engine (OpenAI/Claude/Gemini) im Webinterface nutzen.
- **Mikrofon/Spracheingabe:** funktioniert nur über **HTTPS** (sicherer Kontext) – also hinter einem TLS-Reverse-Proxy (z. B. Nginx Proxy Manager / Caddy) betreiben.
- **QNAP/SMB:** optional, für den automatischen Dokumenten-Abgleich.

Bedienungsanleitung – RAG Wissensdatenbank

V1.0 · Stand: 2026-06-23

Die RAG Wissensdatenbank beantwortet Fragen **ausschließlich** auf Basis deiner hinterlegten Dokumente (Retrieval-Augmented Generation). Diese Anleitung beschreibt die Bedienung für Anwender und Administratoren.

Zur Installation siehe [INSTALL.md](#). Änderungen je Version: [CHANGELOG.md](#).

1. Anmelden

1. Web-Adresse der Wissensdatenbank öffnen (z. B. `https://rag.lan`).
2. Mit Benutzername und Passwort anmelden. Ist 2FA aktiv, zusätzlich den 6-stelligen Code aus der Authenticator-App eingeben.

Die aktuelle **Version** steht unten im Footer (z. B. `V1.0`).

2. Fragen stellen (Chat)

1. Frage ins Eingabefeld tippen und **Senden** (oder Enter).
2. Die Antwort wird live erzeugt (Streaming) und stützt sich nur auf gefundene Dokument-Ausschnitte.
3. Unter der Antwort erscheinen die **Quellen** – anklickbar, öffnet die Originaldatei (bei PDF seitengenau).

Engine wählen: Oben rechts unter „Engine“ das Sprachmodell wählen (z. B. *Lokal·Mac* für lokale Verarbeitung oder eine Cloud-Engine). Steht nichts zur Auswahl, ist die Engine in den Einstellungen noch nicht aktiviert/hinterlegt.

Mehrere Unterhaltungen: Über **+ Neuer Chat** öffnest du einen weiteren Chat-Tab. Tabs lassen sich wechseln und schließen.

3. Spracheingabe (Mikrofon)

- Auf das  **-Symbol** neben dem Senden-Knopf klicken, sprechen, erneut klicken zum Beenden.
- Bei lokaler Engine wird das Audio auf dem Server (Whisper) transkribiert – nichts verlässt das Haus. Bei einer Cloud-Engine nutzt der Browser seine eigene Spracherkennung.
- **Voraussetzung:** Die Seite muss über **HTTPS** laufen (z. B. `https://rag.lan`), sonst gibt der Browser das Mikrofon nicht frei.

4. Darstellung (Light/Dark)

Oben rechts neben dem Zahnrad schaltet das ☀/🌙-Symbol zwischen hellem und dunklem Design um. Die Wahl wird pro Browser gespeichert.

5. Einstellungen (Zahnrad)

5.1 LLM-Zugänge (Admin)

- **Standard-Engine** festlegen (wird genutzt, wenn im Chat nichts anderes gewählt ist).
- Je Engine aktivieren und – bei Cloud-Engines – den API-Schlüssel hinterlegen. Für die lokale Engine die erreichbare Ollama-URL eintragen; über „Ollama-Modelle abrufen“ lässt sich ein Modell auswählen.

5.2 Datenquelle & Dokumente

- **QNAP-Verbindung (SMB):** Host, Freigabe, Unterordner, Benutzer/Passwort. Dateien bleiben auf dem QNAP, indiziert werden nur Text-Ausschnitte.
- **Abgleichen (nur Änderungen):** liest neue/geänderte Dateien ein, entfernt gelöschte – schnell.
- **Voll-Neuaufbau:** verwirft den Index und liest alles neu (nach größeren Umstellungen).
- **Hochladen:** Dateien per Drag & Drop in die Dropzone; sie werden auf den QNAP geschrieben und sofort indiziert. Unterstützt PDF, Word, Excel, PowerPoint, CSV, HTML, Text und Bilder (mit OCR).

5.3 Allgemein (Admin)

- **Trefferanzahl (top_k):** wie viele Text-Ausschnitte je Frage als Kontext dienen (Standard 4; viele/lange Dokumente → 6–8).
- **Suche & Relevanz:** Hybrid-Suche und Reranking ein/aus, Kandidatenzahl, Reranker-Modell.
- **Lizenz:** Lizenzschlüssel eintragen → Status („✓ Lizenziert · Gültig bis ...“). Siehe Abschnitt 7.
- **Logo:** Logo austauschen und Größe anpassen (wirkt auf alle Seiten).

5.4 Mein Konto

- **Passwort ändern.**
 - **2FA (TOTP)** einrichten/deaktivieren: QR-Code mit der Authenticator-App scannen, Code bestätigen.
-

6. Verwaltung (Admin)

Erreichbar über **Einstellungen → Verwaltung** bzw. `admin.html`.

- **Nutzer:** anlegen (Benutzername, Anzeigename, Passwort, Admin-Flag), Gruppen zuweisen, Passwort zurücksetzen, 2FA zurücksetzen, löschen.

- **Gruppen:** definieren, welche **Ordner** eine Gruppe sehen darf (Ordner-ACL). Nutzer sehen nur Dokumente aus ihren freigegebenen Ordnern; Administratoren sehen alles.

Nach Änderungen an Ordnerfreigaben kann ein **Voll-Neuaufbau** nötig sein, damit Altdaten die Berechtigungs-Präfixe erhalten.

7. Lizenz eintragen

1. Im Lizenz Admin einen Schlüssel für das Produkt **RAGW** ausstellen.
2. In der Wissensdatenbank: **Einstellungen** → **Allgemein** → **Lizenz**, Schlüssel einfügen, **Lizenz speichern**.
3. Status sollte auf „**✓ Lizenziert**“ wechseln (mit Ablaufdatum bzw. „Dauerlizenz“).

Ablauf ohne gültige Lizenz: 30 Tage Testzeitraum, danach 10 Tage Kulanz, anschließend ist der Chat gesperrt, bis ein gültiger Schlüssel hinterlegt ist. Ein Banner im Chat weist auf den Status hin.

8. Häufige Probleme

Symptom	Ursache / Lösung
Mikrofon reagiert nicht	Seite läuft nicht über HTTPS → über <code>https://rag.lan</code> (Reverse-Proxy) öffnen.
„Engine nicht verfügbar“	Engine in den Einstellungen aktivieren bzw. API-Schlüssel hinterlegen.
Lokale Engine antwortet nicht	Ollama nicht erreichbar (bei Netbird-Anbindung ggf. <code>netbird up</code> auf dem Mac).
„Ungültiger Schlüssel (Signatur)“	Lizenz-Secret im Server (<code>RAG_LICENSE_SECRET</code>) passt nicht zum Produkt-Secret im Lizenz Admin.
Antwort findet bekannte Info nicht	Trefferanzahl (top_k) erhöhen oder Voll-Neuaufbau des Index.
Chat gesperrt	Lizenz abgelaufen/fehlt → gültigen Schlüssel eintragen (Abschnitt 7).